Datamining project

Objetivos primer hito:

1. Definir la metrica de rendimiento
2. Metodologia de modelos a utilizar
3. Analisis de las variables de entrada

1. Solucion pipeline ColumnTransformer, Pipeline, KNN

Dataset: Predecir si el ingreso de un individuo supera los $50.000 (conjunto del censo)

Analisis de variables:

Nombre	Tipo	Descripcion	Faltantes
Age	Numerico	N/A	no
workclass	Categorico	Privado, Autoempleado-no-inc, Autoempleado-inc, Gobierno Federal, Gobierno Local, Gobierno Estatal, Sin paga, Nunca trabajó.	si
fnlwgt	Numerico	Indica **cuántas personas de la población real representa esa observación del dataset**.	no
education	Categorico	Licenciaturas, profesiones, titulos	no
education-num	Entero	codificacion orfinal de education	no

marital-status	categorico	Cónyuge civil casado, divorciado, nunca casado, separado, viudo, cónyuge casado ausente, cónyuge casado AF.	no
occupation	categorico	Soporte técnico, reparación artesanal, otros servicios, ventas, gerente ejecutivo, especialidad profesional, manipuladores-limpiadores, inspección operativa de máquinas, administrativo, agricultura-pesca, transporte-movimiento, servicio privado, servicio de protección, fuerzas armadas.	si
relationship	categorico	Esposa, Hijo propio, Esposo, No familiar, Otro pariente, Soltero.	no
race / raza	categorico	Blanco, asiático-isleño del Pacífico, amerindio-esquimal, otro, negro.	no
sex	Binario	Femenino, Masculino.	no
capital-gain	Numerico	ganancias por año	no
capital-loss	Numerico	dinero perdido en inversiones o ventas	no
hours-per-week	Numerico	horas promedio semana	no
native-country	Categorico	paises	si
income	binario	>50K, <=50K.	no

Fnlwgt:

- Si una fila tiene `fnlwgt = 200000`, significa que **ese registro representa aproximadamente 200 000 personas con características similares en la población**.
- Se usa para **ajustar estadísticas cuando los datos provienen de una muestra**.

En muchos proyectos de ML:

- Esta variable **se suele eliminar** porque no describe características del individuo, sino **cómo fue ponderada la muestra del censo**.

Education-num:

- Representa **cuántos años de educación formal ha completado la persona**.
- Es una **codificación ordinal** del campo categórico `education`.
- Permite que los algoritmos de machine learning trabajen más fácilmente con el nivel educativo.

Ejemplo:

education	education-num
Preschool	1
1st–4th	2
5th–6th	3
7th–8th	4
9th	5
10th	6
11th	7
12th	8
HS-grad	9
Some-college	10
Assoc-voc	11
Assoc-acdm	12
Bachelors	13
Masters	14
Prof-school	15

education	education-num
Doctorate	16