

UPNA - Minería de Datos

Modelo predictor del autismo

Eloy Urriens
Juan Felipe Pulgarín Lopez
Nicolás Chareca

13 de mayo de 2026

Resumen

Este informe documenta el desarrollo de un modelo de Inteligencia Artificial, utilizando técnicas de minería de datos para la predicción del autismo en personas usando el conjunto de datos `Autism-Adult-Data.csv`. Se describe la limpieza y preparación mediante un **Preparador**, el análisis exploratorio de variables y la definición de componentes del pipeline (imputación, transformación, detección de outliers, estandarización y modelos base). Se especifica la metodología de validación basada en Pipeline + GridSearchCV con estratificación, y las métricas priorizadas (F1-score y AUC de Precisión-Recall). El documento establece el marco metodológico y el flujo de trabajo para el desarrollo y evaluación del modelo.

Índice

1. Introducción	2
1.1. Problema	2
1.2. Análisis de variables	2
2. Rendimiento y validación	3
2.1. Métricas de rendimiento	3
2.2. Metodología utilizada en validación	4
3. Experimentos	4
3.1. Descripción del pipeline	4
3.2. Componentes	4
3.3. Construcción de prototipos	5
3.4. Análisis de la pipeline base	5
3.5. Análisis del componente OutlierDetector	5
3.6. Análisis del componente Estandarizador	5
3.7. Análisis del componente Modelo	5
3.8. Análisis del umbral	5
3.9. Mejor pipeline	6
4. Resultados	6
5. Conclusiones	6

↔

1. Introducción

1.1. Problema

El objetivo del proyecto es la **predicción del autismo en personas** a partir del conjunto de datos `Autism-Adult-Data.csv` [1, 2, 3]. El trabajo se estructura en tres pasos:

- Analizar el problema y las variables disponibles.
- Construir la mejor *pipeline* posible.
- Reflexionar sobre la calidad de la solución.

Preparador

Se implementa un *Preparador* cuyo objetivo es ordenar y limpiar el dataset sin modificar la información relevante. En concreto, realiza:

- Renombrado de columnas y corrección de nombres erróneos.
- Eliminación de columnas innecesarias.
- Inversión del significado en un subconjunto de preguntas.
- Limpieza de texto en variables categóricas.
- Conversión de valores perdidos “?” a NaN.
- Tipado de variables: categóricas y numéricas.

1.2. Análisis de variables

Se analiza la relación entre las variables de entrada y la variable de salida. Cuando se indica $\uparrow$ Autismo o $\downarrow$ Autismo se refiere a un aumento o reducción de la probabilidad de pertenecer a la clase positiva.

Relación de las 10 preguntas con la variable de salida

#	Pregunta	Dirección
1	I often notice small sounds when others do not.	Agree $\rightarrow$ $\uparrow$ Autismo
2	I usually concentrate more on the whole picture, rather than the small details.	Agree $\rightarrow$ $\downarrow$ Autismo
3	I find it easy to do more than one thing at once.	Agree $\rightarrow$ $\downarrow$ Autismo
4	If there is an interruption, I can switch back to what I was doing very quickly.	Agree $\rightarrow$ $\downarrow$ Autismo
5	I find it easy to read between the lines when someone is talking to me.	Agree $\rightarrow$ $\downarrow$ Autismo

6	I know how to tell if someone listening to me is getting bored.	Agree $\rightarrow$ $\downarrow$ Autismo
7	When I'm reading a story, I find it difficult to work out the characters' intentions.	Agree $\rightarrow$ $\uparrow$ Autismo
8	I like to collect information about categories of things.	Agree $\rightarrow$ $\uparrow$ Autismo
9	I find it easy to work out what someone is thinking or feeling just by looking at their face.	Agree $\rightarrow$ $\downarrow$ Autismo
10	I find it difficult to work out people's intentions.	Agree $\rightarrow$ $\uparrow$ Autismo

Relación de variables binarias con la salida

Característica	Dirección
Jaundice (ictericia)	yes $\rightarrow$ $\uparrow$ Autismo
Family pdd	yes $\rightarrow$ $\uparrow$ Autismo
Used app before	yes $\rightarrow$ $\uparrow$ Autismo
Gender	m $\rightarrow$ $\downarrow$ Autismo

Relación de las variables restantes

Nota: En etnia, país de residencia y relación hay pocos datos por categoría, por lo que las tendencias pueden ser engañosas.

- **Ethnicity:** $\uparrow$ Autismo en *black, hispanic, latino, white-european*; $\downarrow$ Autismo en *middle-eastern, pasifika, southasian, turkish*.
- **Age group:** $\uparrow$ Autismo a partir de 30; $\downarrow$ Autismo por debajo de 30.
- **Country of residence** (top 10): $\uparrow$ Autismo en *australia, canada, unitedkingdom, unitedstates*; $\downarrow$ Autismo en *afghanistan, india, jordan, newzealand, srilanka, unitedarabemirates*.
- **Relation:** no aporta información suficiente, por lo que se elimina en etapas posteriores.

2. Rendimiento y validación

2.1. Métricas de rendimiento

Se consideran métricas dependientes e independientes del umbral:

- **Dependientes del umbral:** Accuracy y F1-score.
- **Independientes del umbral:** AUC-ROC y AUC de Precisión-Recall.

Se prioriza el **F1-score** frente a Accuracy debido al desbalance de clases, ya que el F1 combina precisión y recall en la clase positiva. Para métricas independientes del umbral se elige la **AUC de Precisión-Recall** en lugar de la ROC, porque es coherente con la prioridad de detectar bien la clase positiva y es menos optimista en escenarios desbalanceados (desbalance aproximado $\approx 27/73$).

2.2. Metodología utilizada en validación

Se adopta un enfoque de **Pipeline + GridSearchCV**. El dataset tiene alrededor de **700 instancias**, lo que permite realizar validación cruzada sin un coste computacional excesivo.

Razones para usar Pipeline:

- Encadena preprocesado y modelado en un solo objeto.
- Evita fuga de información al ajustar cada transformación solo con datos de entrenamiento.
- Hace el flujo reproducible y mantenible.

Razones para usar GridSearchCV:

- Explora sistemáticamente combinaciones de hiperparámetros.
- Es viable con validación cruzada de 10 folds en este tamaño de datos.
- Devuelve el mejor modelo reentrenado y métricas por combinación para comparar decisiones.

Se consideran distintos esquemas de validación (Hold-Out, K-Fold, Leave-One-Out), y se selecciona **StratifiedKFold** para mantener la proporción de clases en cada fold.

3. Experimentos

3.1. Descripción del pipeline

Se construye la infraestructura para resolver el problema y se definen dos conjuntos de datos: **test** y **resto**. La partición se realiza con una proporción 80/20 y estratificación por clase, codificando la variable objetivo a valores binarios.

3.2. Componentes

Los componentes principales del flujo son:

- **Imputer**: trata valores perdidos en variables numéricas y categóricas.
- **Transformador**: convierte variables categóricas a representación numérica (métodos: orden, conteo, *one-hot* y binario).
- **OutlierDetector**: detecta y reemplaza valores atípicos.
- **Estandarizador**: escala variables numéricas para mejorar el comportamiento de KNN.
- **Modelo**: clasificador base, con dos alternativas: KNN o Árbol de decisión.

Para el modelo se consideran los hiperparámetros más relevantes:

- **KNN**: `n_neighbors`, `weights` (uniform, distance) y `metric` (manhattan, euclidean).
- **Árbol de decisión**: `criterion` (gini, entropy), `min_samples_split`, `min_samples_leaf`, `max_depth`, `ccp_alpha` y `random_state`.

3.3. Construcción de prototipos

Se define una *pipeline* base con **Imputer** + **Transformador**. A partir de ella se construyen prototipos ampliados incorporando opcionalmente **OutlierDetector** y **Estandarizador**, y se elige un clasificador **KNN** o **Árbol de decisión**. Para cada componente se fija un espacio de búsqueda de hiperparámetros.

Componente	Espacio de búsqueda
Imputer	metodo_imputacion_vars_num: media, mediana. metodo_imputacion_vars_cat: moda, missing.
Transformador	metodo_cat_num: orden, conteo, ohe, binary.
OutlierDetector	$k \in \{0,5,1,0,\dots,9,5\}$; deteccion: iqr, mediastd; reemplazo: mediana, media, min, max, moda.
Estandarizador	metodo: minmax, standard, robust.
KNN	n_neighbors: 3, 5, 7, 9, 11, 13; weights: uniform, distance; metric: manhattan, euclidean.
Árbol de decisión	criterion: gini, entropy; min_samples_split: 0.01, 0.05, 0.1; min_samples_leaf: 0.01, 0.05, 0.1; max_depth: 2, 4, $\dots$, 18; ccp_alpha: 0, 0.1, 0.2.

3.4. Análisis de la pipeline base

Contenido pendiente de completar.

3.5. Análisis del componente OutlierDetector

Contenido pendiente de completar.

3.6. Análisis del componente Estandarizador

Contenido pendiente de completar.

3.7. Análisis del componente Modelo

Contenido pendiente de completar.

3.8. Análisis del umbral

Contenido pendiente de completar.

3.9. Mejor pipeline

Contenido pendiente de completar.

4. Resultados

Contenido pendiente de completar.

5. Conclusiones

Contenido pendiente de completar.

Referencias

- [1] Andrew MVD. Autism screening on adults. Kaggle dataset. Accedido 2026-05-12.
- [2] Fadi Thabtah. Autism spectrum disorder screening: Machine learning adaptation and dsm-5 fulfillment. In *Proceedings of the 1st International Conference on Medical and Health Informatics 2017*, pages 1–6, Taichung City, Taiwan, 2017. ACM.
- [3] Fadi Thabtah. Machine learning in autistic spectrum disorder behavioural research: A review. *Informatics for Health and Social Care*, 2017. To appear (December 2017).